

## 1. DATOS “SIMPLES” CADENAS/STRING.

### ¿CADENAS?

Los datos de cadenas, son *secuencias “inmutables”* que contienen **caracteres** encerrados entre comillas (simples, dobles, triples comillas).

- El delimitador de inicio y final debe ser el mismo carácter.
- + Pueden contener:
  - De 0 (cadena vacía) , un carácter, una palabra, una línea o múltiples líneas.
  - Una cadena en Python puede contener tantos caracteres como desees.
  - El único límite son los recursos de memoria de su máquina.

¿*Caracteres*? Según codificación **ASCII, Unicode, bytes**.

### ¿CODIFICACIÓN ASCII, UNICODE?

Codificación ASCII: Están representados todos los caracteres de idiomas como el inglés.

Codificación CP-1252, también conocida como windows-1252 (utilizada en sistemas Windows), Para otros idiomas, como el español.

En CP-1252, los bytes 0 a 127 son iguales que en ASCII (se usan para las letras del alfabeto, los números, etc.). Los bytes 128 a 255 se utilizan para representar otros caracteres, como la ñ.

Tanto ASCII como CP-1252 utilizan un **solo byte** para representar cada carácter.

Codificación UNICODE: Estándar de codificación de caracteres. Permite representar los idiomas que necesitan **más** de un **byte** para representar todos los caracteres disponibles.

Las versiones de Unicode, por aparición son

- **UTF-16**: Codificación Unicode que usa **2 bytes** para representar todos los caracteres. Para poder representar idiomas que requieren de más de 65535 caracteres, utiliza algunos hacks un poco sucios.
- **UTF-32**: Codificación Unicode que usa **4 bytes** para representar todos los caracteres existentes. Cualquier idioma conocido es representable.
- **UTF-8**: Codificación Unicode de **longitud variable**. Usa la misma representación que ASCII para los 128 primeros caracteres, dos bytes para alfabeto latino extendido, 3 bytes para caracteres chinos, y 4 para el resto (no representables con menos de 4 bytes)

### ¿MÚLTIPLES LÍNEAS DE SALIDA?:

Para cadenas de múltiples líneas se utilizan las triples comillas (dobles, o simples).

Aunque, los “fin de línea” son incluidos automáticamente, para asegurar que se inserte un salto de línea después de la triples comilla, agregar una \ al final de la línea.

### ¿SECUENCIAS DE ESCAPE?:

Las secuencias de escape permiten dar otra interpretación a ciertos caracteres, para ello se utiliza la barra invertida (\ ) antes del carácter que debe ser “reinterpretado”.

Las secuencias de escape más utilizadas son:

#### Escapar caracteres especiales:

\'	La comilla simple se considera como otro carácter más, NO como delimitador.
\\"	La comilla doble se considera como otro carácter más, NO como delimitador.
\\	La barra invertida se considera como otro carácter más, NO para “escapar” caracteres

#### Para insertar “teclas de edición”:

\b	Inserta el carácter <b>de retroceso</b> ( BS ) ASCII.
\t	Inserta el carácter <b>de tabulación horizontal</b> (TAB ) ASCII.
\v	Inserta el carácter <b>de tabulación vertical</b> (VT) ASCII .
\r	Inserta el carácter de <b>retorno de carro</b> ( CR ) ASCII .
\n	Inserta el carácter de <b>fin de línea</b> ( LF ) ASCII .

\enter	Eliminar salto de línea en cadenas de líneas múltiples.
\a	Inserta el carácter de campana <b>Bell</b> (BEL) ASCII .
\f	Inserta el carácter de <b>Formfeed</b> (FF) ASCII .

### Para insertar “tipos de objetos”:

\unnnn	Inserta carácter Unicode con valor hexadecimal de 16 bits xxxx
\Unnnnnnnnn	Inserta carácter Unicode con valor hexadecimal de 32 bits xxxx
\onnnn	Objeto de tipo octal
\xnnnn	Objeto de tipo hexadecimal

### Otras:

\N{<name>}	Carácter de la base de datos Unicode con <name> dado
------------	--

¿*PREFIJOS EN LAS CADENAS*?:

Para anular las secuencias de escape

R   r	(Cadenas crudas/sin formato) Los caracteres escapados, con (\), no son “reinterpretados”. Esto es especialmente útil, por ejemplo, para usar las expresiones regulares.
-------	---

Para crear literales de cadena:

U   u	Para crear literales de tipo Unicode (P2).
B   b	Para crear literales de tipo bytes.

¿*TIPOS DE DATOS DE CADENAS*?:

Es una de las mayores diferencias entre Python 2 y 3.

En P3, encontramos: **Unicode**, **byte** y **bytearray** .

En P2, encontramos: Unicode y str(byte).

## 1.1. UNICODE. <CLASS ‘STR’>

¿*ALGUNAS CARACTERÍSTICAS*?:

- Las cadenas de tipo **Unicode** <class ‘str’>.
  - + Son secuencias de **caracteres, inmutables**.
  - + Su contenido está en forma **legible por el ser humano**.
  - + Necesitan ser **codificadas** antes de que se puedan almacenar en el disco.
  - + Pueden contener:
    - De 0 (cadena vacía) , un caracteres, una palabra, una línea o múltiples líneas.
    - Caracteres en codificación Unicode (caracteres de múltiples lenguajes)
    - Secuencias de escape.

### 1.1.1. CREACIÓN.

Encontramos:

- Formato **literal**, entre comillas (simples o dobles) o comillas triples si queremos que sea multilíneas.
  - + Originalmente en P2, pueden seguir usándose los prefijos: u/U, para codificación Unicode.
- Función constructora: [str\(\)](#).

**str (x)** ----- La función constructora [str\(\)](#). Devuelve un tipo **cadena** a partir de una amplia variedad de tipos de datos, incluidas cadenas, literales enteros y literales flotantes.

```
[var_str =] str (objeto [ ,encoding=codificación ,errors=errors ] )
```

- + objeto Cualquier objeto. Especifica el objeto a convertir en una cadena.
- + encoding La codificación del objeto. El valor predeterminado es UTF-8

+ errors Especifica qué hacer si falla la decodificación.

## 1.2. BYTES <CLASS ‘BYTES’>.

¿ALGUNAS CARACTERÍSTICAS?

- Las cadenas de tipo **Byte** <class ‘bytes’>.

+ Son secuencias de caracteres-bytes **inmutables**.

+ Su contenido (internamente almacenado) está en forma solo **legible por la máquina**.

+ Como los objetos Byte son legibles por máquina, pueden **almacenarse directamente en el disco**.

+ Pueden contener:

- Solo permite caracteres en codificación ASCII.
- y algunas secuencias de escape.

### 1.2.1. CREACIÓN.

Encontramos:

- Formato **literal**, entre comillas.

+ Entre comillas (simples o dobles) o comillas triples si queremos que sea multilíneas, pero ahora anteponiendo el prefijo: **b** o **B**.

+ Los bytes con un valor numérico de 128 o mayor deben expresarse con escapes.

+ Los literales de bytes también pueden usar el prefijo **r** para deshabilitar el procesamiento de secuencias de escape.

- Función constructora: [bytes\(\)](#).

**bytes()**-----La función [bytes\(\)](#) . Devuelve un objeto bytes. <class ‘bytes’>.

+ Puede convertir objetos en objetos de bytes, o crear objetos de bytes vacíos del tamaño especificado.

`[var_byte =] bytes (fuente [, encoding , errors ] )`

+ **fuente** Especifica el elemento que se utiliza para crear un objeto de bytes.

. Si es un entero, se creará un objeto de bytes vacío del tamaño especificado.

. Si se trata de una cadena, asegúrese de especificar la codificación de la fuente.

. La función range().

+ encoding La codificación del objeto. El valor predeterminado es UTF-8.

+ errors Especifica qué hacer si falla la decodificación.

## 1.3. BYTEARRAY →<CLASS ‘BYTEARRAY’>.

¿ALGUNAS CARACTERÍSTICAS?

- Las cadenas de tipo **Byterray** <class ‘bytearray’>.

+ Son secuencias de caracteres-bytes **MUTABLES**.

La diferencia entre **bytes ()** y **bytearray ()** es que **bytes ()** devuelve un objeto que no se puede modificar, y **bytearray ()** devuelve un objeto que se puede modificar.

### 1.3.1. CREACIÓN.

- Formato **literal**: No hay una sintaxis literal para los objetos bytearray, en su lugar, siempre se crean llamando a la función constructora.

- Función constructora: [bytearray\(\)](#).

**bytearray(x)**-----La función [bytearray\(\)](#) . Devuelve un objeto una matriz de bytes. <class ‘bytearray’> .

`[var_byteArray =] bytearray (fuente [, encoding [, errors ] ] )`

- + fuente Especifica el elemento que se utiliza para crear un objeto de bytes.
  - . Si es un entero, se creará un objeto de bytes vacío del tamaño especificado.
  - . Si se trata de una cadena, asegúrese de especificar la codificación de la fuente.
  - . Un objeto Copiando los datos binarios existentes a través del protocolo de búfer: bytes(obj)
  - . La función range().
- + encoding La codificación del objeto. El valor predeterminado es UTF-8
- + errors Especifica qué hacer si falla la decodificación. Por defecto ¿?

## 2. MANIPULACIÓN OPERACIONES.

Las cadenas <str> y <bytes> de Python **no pueden ser modificadas** son **inmutables**.

Por eso, asignar a una posición indexada de la cadena resulta en un error:

Si necesitas una cadena diferente, deberías asignar una nueva cadena o crear otra variable.

Las cadenas <bytearray> si son **modificables**.

- “Aritméticas” concatenación (+), copiar (\*):

- Las cadenas de texto pueden ser concatenadas (pegadas juntas) con el operador + y repetidas con \*:

- De “Secuencia”:

- Una cadena-Unicode es una **secuencia de caracteres**.
- La función len() devuelve la longitud de una cadena de texto (número de caracteres).
  - La longitud, de una cadena, dependerá del número de Bytes usados para representarla.
- Las cadenas de texto se pueden **indexar** (subíndices), el primer carácter de la cadena tiene el índice 0.
- Además de la función len() y la indexación (subíndices) y la “rebanada” utilizando corchetes.
  - Los índices son usados para obtener caracteres individuales, las rebanadas para obtener sub-cadenas.

### Recorridos con for in

Tanto para los objetos tipo str como para los objetos tipo bytes, cada carácter se vuelve un elemento iterable.

- Algunas, funciones utilizadas, además de len(), son: la función max(), la función min(), la función sum() (generalmente: sólo para tipo bytes) y la función memoryview() SOLO para tipo byte y bytearray.

- Otras, según sus métodos.

## 3. PASAR DE UN FORMATO A OTRO.

Se utilizan funciones incorporadas y métodos de cadena:

- Para convertir: <str> a <byte>:

- + Anteponer b a la cadena Unicode, SIEMPRE que sea un carácter del ASCII estándar
- + Si es un carácter del ASCII extendido, es necesario utilizar la función bytes() con la codificación correcta/deseada.
- + Con el método de str.encode() con la codificación correcta.

- Para convertir: Byte a Unicode:

- + Utilizando el método byte.decode(), para decodificar es imprescindible especificar la **codificación adecuada** con la que se obtendrá el resultado correcto.
- Si intentamos decodificar con una codificación inadecuada podemos llevarnos una sorpresa, en **forma de error**, o bien, obtener una conversión no deseada:
  - En caso de **error**, se puede:
    - + Ignorar ('ignore' | errors='ignore') El carácter que produce el error se ignora /No se visualiza.
    - + Reemplazar ("replace" | errors='replace') forzar un cambio de caracteres aunque no sea coherente

- De codificación Unicode a carácter que representa y viceversa:

**chr ()** ----- La función [chr\(\)](#) . Devuelve un carácter del código Unicode especificado.

```
[variable =] chr (valor)
```

+ valor Un entero que representa un punto de código Unicode válido.

**ord ()** ----- La función [ord\(\)](#). Convierte un entero que representa el código Unicode del carácter especificado.

```
[variable =] ord (valor)
```

+ valor Un entero que representa un código Unicode válido.

## 4. MÉTODOS DE CADENA.

Listar todas las propiedades/métodos de los objetos: **str, bytes y bytearray**

**Nota:** La mayoría de los métodos son comunes a str y bytes y para bytearray  
Entre los métodos más utilizados están:

### 4.1. PASAR DE UN FORMATO A OTRO.

- De str a bytes:

**encode (x)** ----- El método [encode\(\)](#) //[str.encode\(\)](#) . Devuelve una versión codificada de la cadena como un objeto de bytes.

```
[var_bytes =] <class 'str'>.encode (encoding='utf-8',errors='strict')
```

+ encoding Una cadena que especifica la codificación a utilizar. El valor predeterminado es UTF-8.

+ errors Especifica qué hacer si falla la decodificación. Valores posibles:

- 'backslashreplace' utiliza la barra invertida en lugar del carácter que no se pudo codificar.
- 'ignore'. ignora los caracteres que no pueden ser codificados.
- 'namereplace' reemplaza el carácter por un texto que explica el carácter.
- 'strict'. Por **defecto**, genera un error en caso de fallo
- 'replace'. reemplaza al personaje con un signo de interrogación.
- 'xmlcharrefreplace' reemplaza el carácter con un carácter xml.

- De bytes a str:

**decode (x)** ----- El método / [bytes.decode \(\)](#) .Devuelve una cadena decodificada de los bytes dados..

```
[var_bytes =] <class 'bytes'>.decode (encoding='utf-8',errors='strict')
```

+ encodig La codificación predeterminada es 'utf-8'.

+ errors Esquema de manejo de errores. El valor predeterminado es 'strict', ..

- De bytes a str en hexadecimal (de bytes y Bytearray):

**hex ()** ----- El método hex() .Devuelve un objeto tipo str que contiene la representación en hexadecimal de cada elemento del objeto tipo bytes.

- De str en hexadecimal a bytes:

**fromhex()** ----- El método `fromhex()` . un objeto tipo *bytes* a partir de un objeto *str* que contiene la representación en hexadecimal de uno o más caracteres ASCII.

#### 4.2. PARA “PRESENTACIÓN”:

Tipo de letra:

**capitalize()** ----- El método [capitalize\(\)](#). Devuelve la cadena con la primera letra en mayúsculas.

**lower()** ----- El método [lower\(\)](#). Devuelve la cadena con las letras en minúsculas.

**casefold()** ----- El método [casefold\(\)](#). Convierte la cadena en minúsculas,

**upper()** ----- El método [upper\(\)](#). Devuelve la cadena con las letras en mayúsculas.

**swapcase()** ----- El método [swapcase\(\)](#). Devuelve la cadena con las letras convertidas las mayúsculas en minúsculas y viceversa.

**title()** ----- El método [title\(\)](#). Devuelve la cadena con Formato Título.

Alineación Horizontal:

**center(x)** ----- El método [center\(\)](#). Devuelve la cadena centrada.

**ljust(x)** ----- El método [ljust\(\)](#). Devuelve la cadena alineada a la izquierda.

**rjust(x)** ----- El método ..... Devuelve la cadena alineada a la derecha.

Relleno:

**zfill(x)** ----- El método [zfill\(\)](#). Devuelve la cadena rellena con ceros a la izquierda hasta alcanzar la longitud final indicada.

#### 4.3. PARA BÚSQUEDA:

**count(x)** ----- El método [count\(\)](#). Devuelve un entero representando la cantidad de apariciones de subcadena dentro de cadena.

**find(x)** ----- El método [find\(\)](#). Devuelve un entero representando la posición donde inicia la subcadena dentro de cadena. Si no la encuentra, retorna -1.

**rfind(x)** ----- El método [rfind\(\)](#). Busca en la cadena un valor específico y devuelve la última posición donde se encontró.

**index(x)** ----- El método [index\(\)](#). Busca en la cadena un valor específico y devuelve la posición donde se encontró.

**rindex(x)** ----- El método [rindex\(\)](#). Busca en la cadena un valor específico y devuelve la última posición donde se encontró.

**4.4. PARA “CONFIRMACIONES” VALIDACIÓN:**

Devuelven valores boolean.

**startswith (x)** ----- El método [startswith\(\)](#). Devuelve un valor booleano confirmando si una cadena comienza con una subcadena determinada.

**endswith (x)** ----- El método [endswith\(\)](#). Devuelve un valor booleano confirmando si una cadena finaliza con una subcadena determinada.

**isalnum ()** ----- El método [isalnum\(\)](#). Devuelve un valor booleano confirmando si una cadena es alfanumérica.

**isalpha ()** ----- El método [isalpha\(\)](#). Devuelve un valor booleano confirmando si una cadena es alfábética.

**isdigit ()** ----- El método [isdigit\(\)](#). Devuelve un valor booleano confirmando si una cadena es numérica.

**isdecimal()** ----- El método [isdecimal\(\)](#). Devuelve True si todos los caracteres de la cadena son decimales  
El método isdecimal () devuelve True si todos los caracteres son decimales (0-9).  
Este método se utiliza en objetos Unicode.

**isnumeric ()** ----- El método [isnumeric\(\)](#). Devuelve True si todos los caracteres de la cadena son numéricos

**isupper ()** ----- El método [isupper\(\)](#). Devuelve un valor booleano confirmando si una cadena contiene solo mayúsculas.

**islower ()** ----- El método [islower\(\)](#). Devuelve un valor booleano confirmando si una cadena contiene solo minúsculas.

**isspace ()** ----- El método [isspace\(\)](#). Devuelve un valor booleano confirmando si una cadena contiene solo espacios en blanco.

**istitle ()** ----- El método [istitle\(\)](#). Devuelve un valor booleano confirmando si una cadena tiene Formato De Título.

**isidentifier ()** ----- El método [isidentifier\(\)](#). Devuelve True si la cadena es un identificador.

**isprintable ()** ----- El método [isprintable\(\)](#). Devuelve True si todos los caracteres de la cadena son imprimibles.

**4.5. PARA UNIR O DIVIDIR CADENAS.**

**join (x)** ----- El método [join\(\)](#). Devuelve la cadena uniéndola a un *iterable* (la cadena es separada por cada uno de los elementos del iterable).

**partition (x)** ----- El método [partition\(\)](#). Devuelve una tupla con la cadena partida en varias partes, utilizando un separador.

+ una tupla de tres elementos donde el primero es el contenido de la cadena previo al separador, el segundo, el separador mismo y el ter-

**rpartition (x)** ----- El método [rpartition\(\)](#). Devuelve una tupla en la que la cadena se divide en tres partes

**split (x)** ----- El método [split\(\)](#). Devuelve una lista con la cadena partida en varias partes, utilizando un separador.

**rsplit (x)** ----- El método [rsplit\(\)](#). Divide la cadena en el separador especificado y devuelve una lista.

**splitlines ()** ----- El método [splitlines\(\)](#). Devuelve una lista donde cada elemento es una fracción de la cadena dividida en líneas.

#### 4.6. PARA “REEMPLAZAR” LA CADENA:

**format (x)** ----- El método [format\(\)](#) . Devuelve una cadena formateada sustituyendo texto dinámicamente.

**replace (x)** ----- El método [replace\(\)](#). Devuelve una cadena con texto reemplazado.

**strip (x)** ----- El método [rstrip\(\)](#). Devuelve la cadena eliminando caracteres a la izquierda y derecha de una cadena. Por omisión espacios en blanco.

**lstrip (x)** ----- El método [lstrip\(\)](#) . Devuelve la cadena eliminando caracteres a la izquierda de una cadena. Por omisión espacios en blanco.

**rstrip (x)** ----- El método [rstrip\(\)](#) . Devuelve la cadena eliminando caracteres a la derecha de una cadena. Por omisión espacios en blanco.